

SEMINARSKA NALOGA IZ STATISTIKE
UL FMF, Matematika — univerzitetni študij

Nace Kapus

2017/18

1. (a) Verjetnost, da posamezen anketiranec odgovori z DA, je enaka:

$$\begin{aligned} P(\text{DA}) &= P(\text{DA na delikatno vprašanje})P(\text{delikatno vprašanje}) \\ &\quad + P(\text{DA na nevtrarno vprašanje})P(\text{nevtrarno vprašanje}) \\ &= pq + (1 - p)r := s. \end{aligned}$$

Da je ta verjetnost enaka za vse anketirance, sledi iz naših predpostavk.

- (b) Označimo z I_i indikator dogodka, da i -ti anketiranec odgovori DA. Potem lahko S zapišemo kot vsoto indikatorjev na sledeč način:

$$S = \frac{1}{n} \sum_{i=1}^n I_i.$$

Računamo:

$$\begin{aligned} E(S) &= E\left(\frac{1}{n} \sum_{i=1}^n I_i\right) = \frac{1}{n} \sum_{i=1}^n E(I_i) \\ &= \frac{1}{n} \sum_{i=1}^n s = \frac{1}{n} \cdot ns \\ &= s \end{aligned}$$

Torej je S res nepristranska cenilka za s .

- (c)

$$\begin{aligned} \text{var}(S) &= \text{var}\left(\frac{1}{n} \sum_{i=1}^n I_i\right) = \frac{1}{n^2} \text{var}\left(\sum_{i=1}^n I_i\right) \\ &= \frac{1}{n^2} \left(\sum_{i=1}^n \text{var}(I_i) + \sum_{\substack{i,j=1 \\ i \neq j}}^n \text{cov}(I_i, I_j) \right) \end{aligned}$$

Ker so I_i indikatorji oziroma Bernoullijeve slučajne spremenljivke, zanje velja: $E(I_i) = P(I_i) = s$ in $\text{var}(I_i) = s(1 - s)$. Izračunajmo še $\text{cov}(I_i, I_j)$:

$$\text{cov}(I_i, I_j) = E(I_i I_j) - E(I_i)E(I_j)$$

Naj bo N velikost populacije. $E(I_i I_j) = P(I_i = 1, I_j = 1)$, kar se lahko zgodi na več načinov:

- obema je dodeljeno delikatno vprašanje in oba imata lastnost A
- obema je dodeljeno nevtrarno vprašanje in oba imata lastnost B
- nekdo dobi delikatno vprašanje in ima lastnost A, drugi dobi nevtrarno vprašanje in ima lastnost B

$$\begin{aligned}
E(I_i I_j) &= P(I_i = 1, I_j = 1) \\
&= q \cdot \frac{qN-1}{N-1} \cdot p^2 \\
&\quad + (1-q) \cdot \frac{(1-q)N-1}{N-1} \cdot (1-p)^2 \\
&\quad + 2q \cdot \frac{(1-q)N}{N-1} \cdot p(1-p) \\
&= \frac{N}{N-1} s^2 - \frac{qp^2 + (1-q)(1-p)^2}{N-1}
\end{aligned}$$

Če povzamemo:

$$\begin{aligned}
\text{var}(S) &= \frac{1}{n^2} \left(\sum_{i=1}^n \text{var}(I_i) + \sum_{\substack{i,j=1 \\ i \neq j}}^n \text{cov}(I_i, I_j) \right) \\
&= \frac{1}{n^2} \left(\sum_{i=1}^n s(1-s) + \sum_{\substack{i,j=1 \\ i \neq j}}^n \left(\frac{N}{N-1} s^2 - \frac{qp^2 + (1-q)(1-p)^2}{N-1} - s^2 \right) \right) \\
&= \frac{1}{n} \left(s(1-s) + (n-1) \left(\frac{N}{N-1} s^2 - \frac{qp^2 + (1-q)(1-p)^2}{N-1} - s^2 \right) \right)
\end{aligned}$$

- (d) Kadar gre $N \rightarrow \infty$, gre $\text{cov}(I_i, I_j)$ proti 0. V tem primeru velja, da je

$$\text{var}(S) \sim \frac{s(1-s)}{n}.$$

- (e) Nepristranska cenilka za q obstaja v primeru, ko je p različen od 0 (vsaj kdo dobi delikatno vprašanje). Iz enakosti

$$s = pq + (1-p)r$$

lahko izrazimo cenilko za q , in sicer:

$$\hat{q} = \frac{S - (1-p)r}{p}.$$

(f) Iz prejšnje točke sledi:

$$\text{var}(\hat{q}) = \text{var}\left(\frac{S}{p}\right) \sim \frac{s(1-s)}{np^2}.$$

2. Povprečni dohodek izračunamo iz dohodkov družin, katere smo izbrali s slučajnim vzorčenjem. Če bi vzorčili ponovno, bi (najverjetneje) izbrali druge družine ter posledično dobili drugačen rezultat. Torej je to res slučajna spremenljivka.

3.

4.

5. (a)

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i \quad / : \rho_i$$

$$\frac{Y_i}{\rho_i} = \beta_0 \frac{1}{\rho_i} + \beta_1 \frac{x_i}{\rho_i} + \frac{\varepsilon_i}{\rho_i}$$

$$Z_i = \beta_0 c_i + \beta_1 d_i + e_i$$

Da nov model zadošča predpostavkam standardne linearne regresije, mora zanj veljati: $E(e_i) = 0$, $\text{var}(e_i) = \sigma^2$, ter $\text{cov}(e_i, e_j) = 0$ za $i \neq j$. Računamo:

$$E(e_i) = E\left(\frac{\varepsilon_i}{\rho_i}\right) = \frac{1}{\rho_i} \cdot 0 = 0$$

$$\text{var}(e_i) = \text{var}\left(\frac{\varepsilon_i}{\rho_i}\right) = \frac{1}{\rho_i^2} \text{var}(\varepsilon_i) = \frac{\rho_i^2 \sigma^2}{\rho_i^2} = \sigma^2$$

$$\text{cov}(e_i, e_j) = \text{cov}\left(\frac{\varepsilon_i}{\rho_i}, \frac{\varepsilon_j}{\rho_j}\right) = \frac{1}{\rho_i \rho_j} \text{cov}(\varepsilon_i, \varepsilon_j) = 0$$

Matrika modela je enaka

$$X = \begin{bmatrix} \frac{1}{\rho_1} & \frac{x_1}{\rho_1} \\ \frac{1}{\rho_2} & \frac{x_2}{\rho_2} \\ \vdots & \vdots \\ \frac{1}{\rho_n} & \frac{x_n}{\rho_n} \end{bmatrix}$$

(b) V novem modelu minimiziramo količino

$$\sum_{i=1}^n (z_i - \beta_0 c_i - \beta_1 d_i)^2.$$

Računamo:

$$\sum_{i=1}^n (z_i - \beta_0 c_i - \beta_1 d_i)^2 = \sum_{i=1}^n \left(\frac{Y_i}{\rho_i} - \beta_0 \frac{1}{\rho_i} - \beta_1 \frac{x_i}{\rho_i} \right)^2 = \sum_{i=1}^n \frac{(Y_i - \beta_0 - \beta_1 x_i)^2}{\rho_i^2}$$

Komentar: funkcija, ki jo želimo minimizirati v novem modelu je zelo podobna funkciji izhodiščnega modela, pojavijo se le faktorji $\frac{1}{\rho_i^2}$. To pomeni, da imajo v funkciji, ki jo minimiziramo, večji pomen opažanja, ki imajo manjše variance in obratno.

(c) Ker imamo standarden linearni regresijski model vemo:

$$\begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{bmatrix} = (X^T X)^{-1} X^T z,$$

pri čemer je

$$X = \begin{bmatrix} \frac{1}{\rho_1} & x_1 \\ \frac{1}{\rho_2} & x_2 \\ \vdots & \vdots \\ \frac{1}{\rho_n} & x_n \end{bmatrix} \text{ in } z = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}.$$

Izračunamo:

$$X^T X = \begin{bmatrix} \sum_{i=1}^n \frac{1}{\rho_i^2} & \sum_{i=1}^n \frac{x_i}{\rho_i^2} \\ \sum_{i=1}^n \frac{x_i}{\rho_i^2} & \sum_{i=1}^n \frac{x_i^2}{\rho_i^2} \end{bmatrix}, \quad X^T z = \begin{bmatrix} \sum_{i=1}^n \frac{y_i}{\rho_i^2} \\ \sum_{i=1}^n \frac{x_i y_i}{\rho_i^2} \end{bmatrix}.$$

Od tod sledi:

$$\hat{\beta}_0 = \frac{\sum_{i=1}^n \frac{x_i^2}{\rho_i^2} \sum_{i=1}^n \frac{y_i}{\rho_i^2} - \sum_{i=1}^n \frac{x_i}{\rho_i^2} \sum_{i=1}^n \frac{x_i y_i}{\rho_i^2}}{\sum_{i=1}^n \frac{1}{\rho_i^2} \sum_{i=1}^n \frac{x_i^2}{\rho_i^2} - \sum_{i=1}^n \frac{x_i}{\rho_i^2} \sum_{i=1}^n \frac{x_i}{\rho_i^2}}$$

$$\hat{\beta}_1 = \frac{-\sum_{i=1}^n \frac{x_i}{\rho_i^2} \sum_{i=1}^n \frac{y_i}{\rho_i^2} + \sum_{i=1}^n \frac{1}{\rho_i^2} \sum_{i=1}^n \frac{x_i y_i}{\rho_i^2}}{\sum_{i=1}^n \frac{1}{\rho_i^2} \sum_{i=1}^n \frac{x_i^2}{\rho_i^2} - \sum_{i=1}^n \frac{x_i}{\rho_i^2} \sum_{i=1}^n \frac{x_i}{\rho_i^2}}.$$

(d) Po formuli iz predavanj:

$$\text{var} \left(\hat{\beta}_0 \right) = \sigma^2 \left[(X^T X)^{-1} \right]_{11} = \sigma^2 \cdot \frac{\sum_{i=1}^1 \frac{x_i^2}{\rho_i^2}}{\sum_{i=1}^n \frac{1}{\rho_i^2} \sum_{i=1}^n \frac{x_i^2}{\rho_i^2} - \sum_{i=1}^n \frac{x_i}{\rho_i^2} \sum_{i=1}^n \frac{x_i}{\rho_i^2}}$$

$$\text{var} \left(\hat{\beta}_1 \right) = \sigma^2 \left[(X^T X)^{-1} \right]_{22} = \sigma^2 \cdot \frac{\sum_{i=1}^1 \frac{1}{\rho_i^2}}{\sum_{i=1}^n \frac{1}{\rho_i^2} \sum_{i=1}^n \frac{x_i^2}{\rho_i^2} - \sum_{i=1}^n \frac{x_i}{\rho_i^2} \sum_{i=1}^n \frac{x_i}{\rho_i^2}}$$